Projet Bibliographique

Comment les technologies de séquençage long read peuvent-elles améliorer l'analyse de l'ADN environnemental et comment traiter bioinformatiquement ces données ?

Rédigé par :

Mathilde Chatain

mathilde.chatain@etu.umontpellier.fr

Encadrée par :

Maeva Leitwein

maeva.leitwein@ldgenx.fr

Emilie Delpuech

emilie.delpuech@ldgenx.fr

Sous la tutelle de :

Anthony Boureux

anthony.boureux@umontpellier.fr

M1 - Master Bioinformatique

Université de Montpellier

Septembre – Décembre 2025

Table des matières

1 Introduction **1**

2 Les différentes méthodes analytiques **2**

2.1 Barcoding 3

2.2 Metabarcoding 3

2.3 Métagénomique 5

3 Les technologies de séquençage **6**

3.1 Lectures courts fragments 6

3.2 Lectures longs fragments 7

3.3 Tableau récapitulatif 10

4 Pipeline Informatique **11**

4.1 Architecture d'un pipeline informatique 11

4.1.1 Pré-traitement et contrôle qualité des lectures 11

4.1.2 Assemblage / mapping des lectures 12

4.1.3 Définition des unités (features) : OTUs et ASVs 13

4.1.4 Annotation taxonomique 14

4.1.5 Base de données pour les lectures longues : enjeux et limites . . 14

4.1.6 Analyse 15

4.2 Exemple de pipelines informatiques 15

4.2.1 Description globale de FROGS et SAMBA 16

4.2.2 Tableau comparatif de FROGS et SAMBA 18

5 Conclusion **19**

6 Bibliographie **20**

7 Annexes **22**

1 Introduction

Dans un contexte de déclin de la biodiversité et de transformations profondes de ses écosystèmes, la détection et la surveillance des espèces constituent un enjeu majeur. Ces démarches peuvent s'appuyer sur des méthodologies innovantes telles que l'analyse de **l'ADN environnemental**.

L'ADN environnemental (ou ADNe) correspond à l'ensemble des fragments d'ADN libérés dans l'environnement par les organismes du vivant. Ces fragments, issus de spores, d'excrétions ou encore de tissus en décomposition, se retrouvent dans l'eau, le sol et les sédiments.
L'analyse de ces fragments permet de déterminer les espèces présentes dans le milieu, sans avoir à les observer ni à les capturer directement.
L'article de Deng et al. [1] en est un parfait exemple : utiliser l'ADNe afin d'évaluer la diversité piscicole de la rivière Danjiang en Chine, révélant un nombre d'espèces bien supérieur à celui obtenu par des méthodes classiques de capture.

L'utilisation de l'ADNe dans ce contexte permet ainsi d'éviter la destruction des habitats, la sous-représentation d'espèces rares ou menacées et également de détecter des espèces discrètes ou cryptiques, difficilement observables à l'œil nu.

Au début des années 2000, les technologies de séquençage Sanger ont permis de mener les premières études notamment grâce à la méthode analytique du *barcoding*. Cette méthode utilise des régions génomiques standardisées propres à chaque espèce, pour constituer de larges bibliothèques d'ADN permettant donc l'identification de spécimens inconnus, à l'instar de l'ARN ribosomal 16S utilisé pour l'identification bactérienne.

Cependant, le séquençage Sanger, qui ne peut analyser qu'une espèce à la fois, s'avère inadapté lorsque les échantillons contiennent un mélange d'ADN provenant d'environnements complexes.

Depuis 2005, l'émergence du séquençage de nouvelle génération (NGS), tel qu'Illumina, a donné un nouvel élan aux études sur l'ADN environnemental, en permettant de séquencer simultanément de très nombreux fragments d'ADN. Ces technologies de séquençage sont aujourd'hui les plus utilisées dans le domaine de l'ADNe. Mais nous verrons dans ce projet que les lectures générées, généralement courtes (dites *short reads* en anglais), compliquent l'identification de l'espèce.

C'est dans ce contexte qu'émergent les technologies de séquençage à lectures longues (*long reads*) dans les années 2010, développées notamment par PacBio ou NanoPore, qui ont permis de surmonter cette limite. Nous montrerons que les lectures longues offrent une meilleure résolution taxonomique - c'est à dire une forte capacité à identifier les organismes (jusqu'au niveau de l'espèce, voire de la sous-espèce).

Ainsi, la question centrale de ce projet bibliographique est de déterminer **dans quelle mesure les technologies à lectures longues peuvent améliorer la détection et la caractérisation de la biodiversité à partir d'ADNe, comparativement aux approches à lectures courtes. Puis nous présenterons l'architecture d'un pipeline informatique avant de comparer deux d'entre eux : FROGS et SAMBA.**

Pour comprendre l'impact des technologies de séquençage sur l'ADNe, il est d'abord nécessaire de rappeler les principales méthodes analytiques utilisées.

2 Les différentes méthodes analytiques

Les méthodes analytiques définissent la stratégie d'analyse des séquences d'ADNe à mettre en place. Elles permettent de choisir ce que l'on veut cibler dans ces séquences et définissent la préparation de l'échantillon à réaliser.

2.1 Barcoding

La méthode du *barcoding* repose sur l'amplification (via PCR, Polymerase Chain reaction ; qPCR, quantitative PCR ; ou ddPCR, Digital Droplet PCR) d'un gène marqueur spécifique à une espèce permettant d'identifier uniquement cette espèce.
Plusieurs régions cibles sont couramment utilisées telles que COI pour les animaux, ITS pour les champignons ou encore rcbL et matK pour les plantes. Ces marqueurs sont recensés dans des bases de données telles que BOLD, centralisant les séquences de référence de marqueurs.

Simple et peu coûteuse, la méthode du barcoding est particulièrement utile lorsque l'objectif est d'identifier précisément une espèce cible unique. Par exemple, l'article de Faure et al. [2] décrit une étude utilisant le barcoding pour cartographier la distribution de *Squatina squatina* en Corse, révélant la présence de l'espèce dans des zones où elle n'avait jamais été observée auparavant. Dans cette étude, un fragment de 173 pb du gène COI a été amplifié en qPCR puis confirmé par séquençage Sanger.

Cependant cette approche, traditionnellement utilisée avec la technologie de séquençage Sanger, ne permet d'analyser qu'une seule espèce à la fois. Elle devient donc inadaptée lorsqu'il s'agit d'identifier simultanément plusieurs organismes présents dans un même échantillon d'ADNe, situation fréquente dans les analyses environnementales.

2.2 Metabarcoding

La méthode du *métabarcoding* présente un avantage majeur par rapport au barcoding : elle permet d'analyser des échantillons complexes. En effet cette méthode permet de séquencer en un seul run, les fragments amplifiés d'un ou de plusieurs marqueurs génétiques communs aux différentes espèces présentes dans l'échantillon (voir Figure 1 ci-dessous).

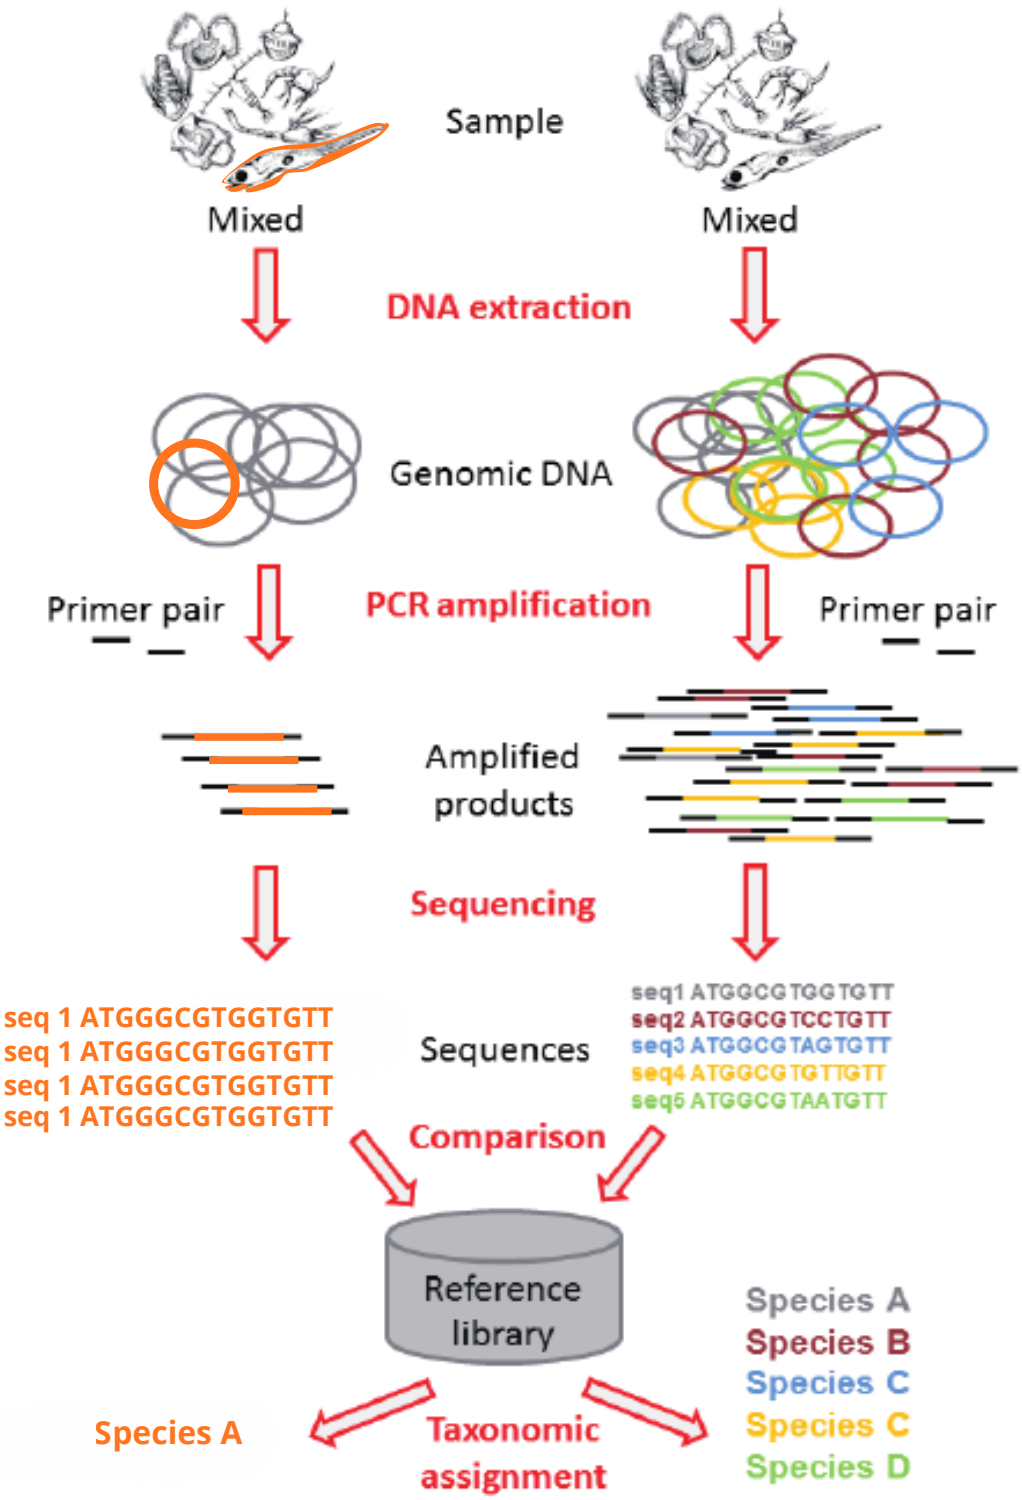

FIGURE 1 – Schéma des méthodes de barcoding (à gauche) et de métabarcoding (à droite) - inspiré de Corell et Rodriguez-Ezpeleta (2014).

L'étude d'Espinosa et al. [3] illustre cela en combinant plusieurs marqueurs (deux ADN nrDNA ITS1 et ITS2, et deux cpDNA rbcL et trnL) afin d'identifier les plantes aquatiques et terrestres. Étant donné l'absence d'un marqueur universel pour les plantes (ne parvenant pas à discriminer toutes les espèces), cette approche "multi-gènes" permet la détection d'espèces dans l'ensemble du règne végétal ainsi que des espèces étroitement apparentées.

Cette méthode s'avère donc particulièrement efficace pour décrire la diversité spécifique d'un écosystème dans son ensemble, contrairement au barcoding qui cible une espèce précise.

Par ailleurs elle permet aussi de révéler la présence d'espèces exotiques, rares ou à faible abondance comme le montre l'étude de Deng et al. [1] par la détection de poissons rares et exotiques. Ces résultats démontrent la capacité du métabarcoding à fournir une image globale et assez fine de la biodiversité aquatique présente dans un milieu donné.

Bien que cette méthode ait permis d'identifier près du double d'espèces par rapport aux observations de terrain, l'article d'Espinosa et al. [3] souligne une tendance aux faux positifs. En effet, la grande sensibilité du métabarcoding peut conduire à la détection de traces d'ADN résiduel provenant d'espèces non réellement présentes dans le milieu étudié, entraînant donc une surestimation de la diversité observée.

2.3 Métagénomique

La *métagénomique* se distingue de ces deux approches : elle ne se limite pas à un seul gène marqueur, mais **séquence l'ensemble du matériel génétique présent dans l'échantillon**, il n'y a donc pas d'amplification PCR. Elle permet d'obtenir une vision beaucoup plus complète des communautés présentes dans l'environnement.

Bien qu'historiquement les études métagénomiques se soient appuyées sur des lectures courtes, les technologies de séquençage de troisième génération (lectures longues) présentent un intérêt croissant, notamment en raison de la richesse des informations qu'elles fournissent, utiles pour l'alignement et la comparaison des séquences.

C'est justement dans la partie suivante que nous examinerons les principales différences qui subsistent entre l'utilisation de lectures courtes et longues, et ce que peuvent offrir les lectures longues quant à l'analyse de l'ADNe.

3 Les technologies de séquençage

Les technologies de séquençage à haut débit se divisent en deux grandes catégories :

- **Les technologies de séquençage à lectures courtes (*short reads*)**, telles qu'Illumina, Aviti ou IonTorrent, produisant des fragments généralement compris entre 100 et 300 pb.
- **Les technologies de séquençage à lectures longues (*long reads*)**, telles que Oxford Nanopore Technologies (ONT) ou PacBio, capables de séquencer des fragments de plusieurs kilobases, pouvant atteindre 30 à 50kb. [4, 5].

3.1 Lectures courts fragments

Les lectures courts fragments ont permis d'énormes progrès notamment grâce à leur **rapidité, leur moindre coût** et la production d'un grand nombre de fragments. Chaque fragment est séquencé de nombreuses fois, assurant une **profondeur très élevée** et permettant de corriger efficacement les erreurs. Cet atout est l'un des principaux avantages à l'utilisation des lectures courtes.

Elles rencontrent toutefois des limites, notamment une **résolution taxonomique réduite** (difficulté à distinguer des espèces proches). En effet, malgré une profondeur très élevée, ces fragments de petite taille apportent une information génétique limitée, ce qui empêche une assignation taxonomique fiable au niveau de la famille, genre ou espèce. Comme le confirment Rousseau et al. [6], l'affectation taxonomique basée sur de courts fragments (400 pb) est insuffisante pour discriminer les séquences au niveau de l'espèce.

Cette limitation est illustrée en Figure 2 ci-dessous, qui compare la couverture génomique obtenue à partir de courtes et de longues lectures. Les lectures courtes laissent apparaître de nombreuses zones non-couvertes (sequence gaps) le long de la séquence cible tandis que les lectures longues permettent une couverture plus continue et complète, améliorant la résolution taxonomique ainsi que la qualité de l'assemblage.

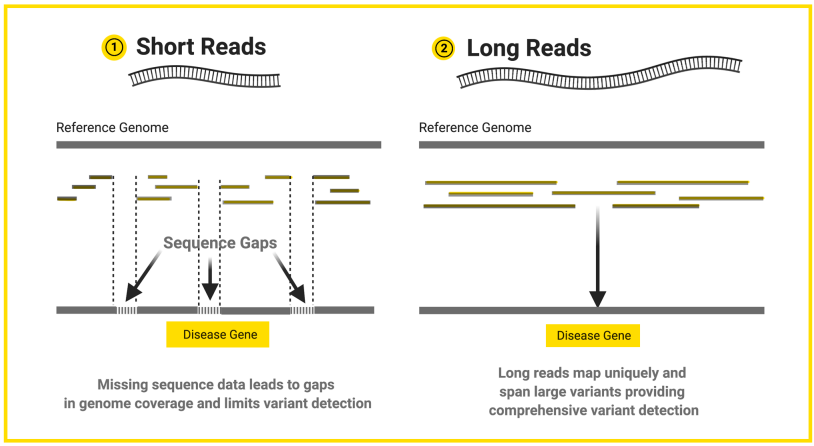

FIGURE 2 – Schéma représentant les zones non-couvertes (sequence gaps) par l'utilisation des lectures courtes (gauche) VS les lectures longues (à droite) [7]

3.2 Lectures longs fragments

Pour pallier ces limites, les lectures longues, rendues possibles par les technologies de séquençage à haut débit de troisième génération (HTS) telles que ONT (Oxford Nanopore Technologies) ou encore PacBio, sont de plus en plus utilisées. Terdesoo et al. [4] argumentent le fait que les technologies à lectures longues sont très prometteuses pour l'écologie microbienne, et par extension pour tous domaines utilisant des échantillons complexes d'ADN environnemental.

Ces lectures longues offrent une **meilleure résolution** que celles à lectures courtes, lorsqu'elles sont alliées à des méthodes de métabarcoding [5].
Cela est démontré à travers l'étude menée sur des poissons plats : le nombre de différences nucléotidiques entre espèces proches est bien plus élevé dans les lectures longues (2kb) que dans les lectures courtes (270pb).

Pour trois espèces proches (*Raja montagui, Raja microocellata* et *Raja brachyura*), il a été détecté maximum 4 différences nucléotidiques pour la lecture courte contre 53 différences pour la lecture longue, voir graphique ci-dessous (cas E de la Figure 3).

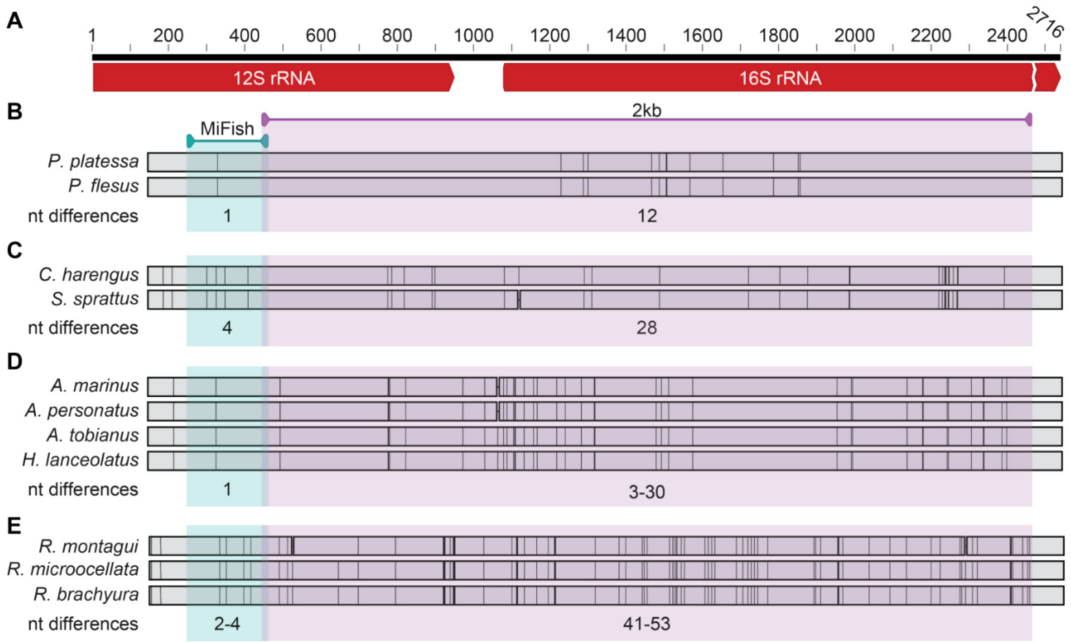

FIGURE 3 – Comparaison du nombre de différences nucléotidiques entre lectures courtes et longues chez différentes espèces de raies - tiré de l'article de Doorenspleet et al. (2025) [5]

De même les auteurs Ritter et al.[8] ont utilisé des technologies de séquençage longue lecture pour étudier la diversité fongique en Amazonie. Ces longs fragments ont permis une meilleure résolution taxonomique et une identification plus fiable des espèces, y compris les espèces rares ou complexes, comparativement aux lectures courtes classiques.

Ainsi, les lectures longues permettent une **meilleure identification des espèces très proches** car elles couvrent des régions génomiques beaucoup plus étendues.

A l'origine, le principal frein à l'utilisation des technologies de séquençage associées à la lecture longue résidait dans le **taux d'erreur** [6].

Par exemple pour le séquençage des nanopores ce taux d'erreur se situait environ à 15% à son lancement [9], mais il peut être maintenant surmonté via des outils bioinformatiques et une amélioration continue dans la préparation de la bibliothèque (librairie) de séquençage. [4]

Tout comme les technologies PacBio, qui présentaient initialement un taux d'erreur élevé, celui-ci a considérablement diminué (de 25 % à environ 10–12 % en une décennie). Grâce aux avancées récentes, notamment avec la technologie PacBio HiFi/CCS, le taux d'erreur est désormais inférieur à 1 % [4].

Cependant, le coût de séquençage pour les lectures longues demeure plus élevé que celui des technologies à lectures courtes, limitant leur utilisation à grande échelle. Ainsi, les technologies à lecture courte, moins coûteuses, peuvent être préférables lorsque la résolution taxonomique au niveau de l'espèce est moins cruciale.[4]

En conclusion, pour des échantillons environnementaux où l'ADN est souvent retrouvé fragmenté et dégradé, les lectures longues offrent une meilleure précision, améliorent la détection et l'identification des espèces, tandis que les lectures courtes restent plus rapides et plus économiques

3.3 Tableau récapitulatif

Méthode	Principe	Type lectures et séquençage	Avantages principaux	Limites principales
Barcoding	Amplification 1 seul gène marqueur afin d'identifier une espèce précise.	Courtes lectures *Sanger,qPCR, digital PCR*	Identification précise d'une espèce Méthode simple et moindre coût	Analyse limitée à une seule espèce.
Métabarcoding (short reads)	Amplification / séquençage simultané d'un ou plusieurs marqueurs génétiques partagés entre espèces.	Courtes lectures *Illumina*	Analyse simultanée de nombreuses espèces Image globale de la biodiversité.	Risque faux positifs. Résolution taxonomique parfois limitée.
Métabarcoding (long reads)	Même principe, mais avec des séquences plus longues couvrant des gènes complets.	Longues lectures *Nanopore, PacBio*	Haute résolution taxonomique (jusqu'à la sous-espèce) Identification facilitée.	Coût élevé Augmentation du coût de stockage des données. Analyses bioinformatiques plus complexes et plus lourdes.
Métagénomique	Séquençage de l'ensemble du matériel génétique de l'échantillon (sans amplification ciblée).	Courtes, longues lectures *Illumina, Nanopore, PacBio*	Vue complète des communautés Accès à la diversité fonctionnelle	Coût élevé et analyse complexe. Ressources informatiques importantes. Bases de données parfois incomplètes.

TABLE 1 – Comparaison des principales méthodes analytiques et types de séquençage appliqués à l'ADN environnemental (ADNe).

4 Pipeline Informatique

4.1 Architecture d'un pipeline informatique

L'analyse de l'ADNe repose sur une série d'étapes bioinformatiques permettant de transformer ces lectures brutes issues du séquençeur en lectures interprétables.

Ces étapes peuvent varier selon que l'on analyse des lectures courtes ou longues, cependant elles reposent toutes deux sur une architecture commune. Chacune des ces étapes peut être réalisée par différents outils bioinformatiques.

Nous présenterons ici les principales étapes d'un pipeline bioinformatique standard.

4.1.1 Pré-traitement et contrôle qualité des lectures

Cette étape vise à **évaluer la qualité des lectures et à filtrer celle-ci** en éliminant les séquences trop courtes, de mauvaise qualité, contenant des erreurs de séquençage ou encore contaminées. Cette étape est nécessaire, en particulier pour des échantillons ADNe qui sont très sensibles aux contaminations et où l'ADN est souvent très fragmenté.

Le contrôle qualité est classiquement réalisé à l'aide d'outils tels que **FASTQC** ou **PycoQC** (spécifique aux lectures longues). Ils ne procèdent pas à un filtrage des lectures mais fournissent une analyse descriptive sous forme de graphiques, permettant d'évaluer la qualité globale des données de séquençage (court ou long fragment).
Des outils de pré-traitement tels que **Trimmomatic** peuvent ensuite être utilisés pour nettoyer les lectures courtes. Le traitement des adaptateurs dans les données de fragments longs avec ONT repose sur des outils dédiés aux lectures longues, tels que **Porechop**, permettant le trimming des adaptateurs et la gestion du démultiplexage, étapes essentielles pour l'analyse de séquences d'ADN longs. Cette combinaison d'outils permet d'optimiser la fiabilité des données avant de les analyser bioinformatiquement, et limite ainsi l'apparition de faux positifs. Nous verrons que dans le pipeline *FROGS*, l'outil **VSEARCH** est utilisé pour le filtrage des séquences, l'élimination des chimères et le regroupement des lectures strictement identiques, contribuant ainsi à la qualité et à la robustesse des analyses métabarcoding.

4.1.2 Assemblage / mapping des lectures

Cette étape a pour objectif de reconstituer les séquences génomiques à partir des fragments lus. Pour cela, deux approches principales existent :

— **Le mapping**, qui consiste à aligner les lectures sur une séquence de référence ou une base de données contenant des séquences de référence afin d'identifier les espèces.

— **L'assemblage *de novo***, employé lorsqu'aucune séquence de référence n'est disponible. Cette approche vise à reconstruire les génomes sans référence et repose notamment sur l'utilisation de lectures longues, qui permettent une meilleure résolution des régions répétitives ou complexes.

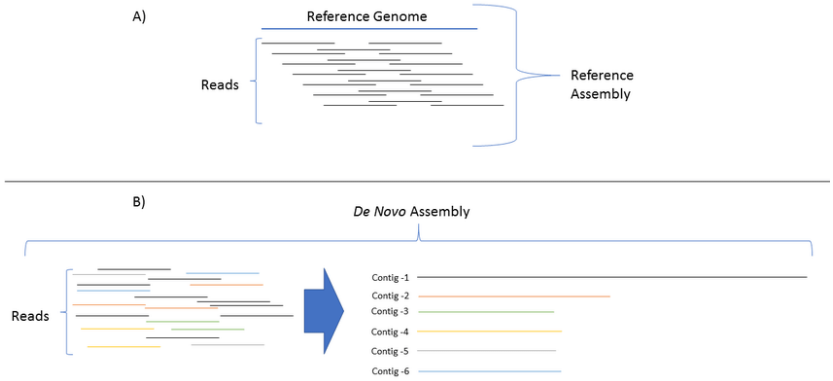

FIGURE 4 – Schéma de l'étape de mapping et celle d'un assemblage de novo - Dynamics, Diversity and Evolution of Baculoviruses, Christopher Noune 2017).

Les mappeurs les plus utilisés sont **BWA-MEM, Bowtie2** ou encore **Minimap2**, ils permettent d'aligner les lectures sur une base de référence (mapping). Parmi ces outils, Minimap2 est reconnu comme l'un des mappeurs les plus rapides et les plus robustes. L'article de Li et al. [9] montre qu'il surpasse largement les mappeurs classiques : trois à quatre fois plus rapide pour les lectures courtes, et jusqu'à trente fois plus rapide pour les lectures longues. Combinant vitesse et précision, cet outil est recommandé pour le mapping de lectures longues.

4.1.3 Définition des unités (features) : OTUs et ASVs

Afin de rendre les données biologiquement interprétables, les séquences sont regroupées en unités appelées OTUs (*Operational Taxonomic Units*) ou ASVs. Le regroupement en OTUs (*Operational Taxonomic Units*) a pour objectif de rassembler des séquences similaires selon un seuil de similarité prédéfini, le plus souvent fixé à 97% d'identité nucléotidique. Ainsi toutes les séquences dépassant ce seuil de similarité sont regroupées dans une même unité, supposant représenter une espèce ou un groupe taxonomique proche. Cette approche permet de réduire le bruit lié aux erreurs de séquençage et de simplifier les jeux de données, mais elle repose sur un seuil arbitraire qui peut conduire à la fusion de séquences biologiquement distinctes.

A l'inverse les ASVs ne reposent pas sur un clustering par seuil de similarité : chaque variation réelle est conservée. Ainsi, chaque ASV correspond à une séquence unique, distinguée au nucléotide près, ce qui permet de conserver les variations fines entre séquences proches.
Le choix entre OTUs et ASVs dépend à la fois du pipeline bioinformatique utilisé et du type de lectures analysées.

Dans le pipeline de FROGS, présenté dans la partie suivante, ce regroupement est réalisé via l'outil **SWARM**. Celui-ci diffère des autres outils de clustering d'OTUs car il n'impose aucun seuil global [10] mais utilise des distances locales entre les séquences (par exemple le nombre de nucléotides différents). Cette approche permet un clustering adaptatif, plus sensible aux micro-variations, tout en limitant la fusion arbitraire des séquences. D'autres outils de clustering existent tel que **QIIME2** (regroupement en OTUs) et **DADA2** (infère les ASVs), adaptés aux courtes lectures et notamment intégrés dans le pipeline de SAMBA.

Les ASVs offrent une résolution de séquence plus fine que les OTUs (en distinguant des variations nucléotidiques parfois limitées à une seule base) mais cette résolution accrue n'implique pas nécessairement une meilleure précision taxonomique. En effet, l'assignation taxonomique dépend avant tout de la longueur du fragment séquencé, de la région génomique ciblée et de la qualité des bases de données de référence.

4.1.4 Annotation taxonomique

L'annotation taxonomique représente une étape essentielle du pipeline bioinformatique puisqu'elle permet **d'attribuer une identité taxonomique à chaque séquence.** C'est à partir des séquences, filtrées et corrigées, que les fragments d'ADN sont comparés à des bases de données pour déterminer l'espèce. Parmi les outils les plus fréquemment utilisés, on retrouve Kraken2, Bracken et Centrifuge, qui réalisent cette classification taxonomique.

L'étude de Govender et al. [11] a comparé ces classifieurs à partir de courtes lectures (Illumina) et de longues lectures (Nanopore), en combinaison avec une analyse métagénomique. Les auteurs ont démontré que l'outil Bracken présentait la meilleure performance avec une médiane de 97,8% de lectures correctement assignées à l'espèce. Comparativement, celle de Kraken atteignait les 86,4%. Néanmoins cela est influencé par la base de données utilisée : sa richesse et sa taille sont déterminantes pour la précision taxonomique.

L'outil BLAST peut être utilisé pour l'annotation taxonomique des séquences longues [5], permettant une identification précise des espèces en comparant les séquences à une base de référence adaptée. BLAST est également utilisé dans le pipeline de FROGS.

4.1.5 Base de données pour les lectures longues : enjeux et limites

Comme nous l'avons vu, l'annotation taxonomique repose sur la comparaison des séquences avec des bases de données de référence. Ainsi la précision de l'identification des espèces dépend directement de la qualité des bases de données utilisées. Concernant les lectures courtes il existe de nombreuses bases de données complètes, contenant des séquences issues de fragments courts. En revanche, pour les lectures longues les bases de données disponibles sont limitées avec peu de séquences longues référencées.

Cet aspect est souligné dans l'article de Terdersoo et al. [4] : la plupart des bases de données de gènes marqueurs populaires contiennent des séquences de longueur variable, mais souvent plus courtes que les amplicons de lectures longues, ce qui limite la résolution taxonomique atteignable.

Une stratégie pour améliorer la précision des analyses des lectures longues serait de créer des bases de données dédiées aux fragments longs. Par exemple dans le cadre de l'étude des poissons, il est envisageable de constituer une base de données regroupant l'ensemble des gènes COI de référence.

Pour les champignons et autres eucaryotes, la base de données UNITE intègre des annotations réalisées par les utilisateurs sur plusieurs gènes marqueurs, avec un sous-ensemble de référence spécifiquement conçu pour les longues séquences (version 9). [4]

4.1.6 Analyse

L'étape d'analyse correspond à l'interprétation des résultats et permet d'évaluer la biodiversité, ainsi que de confirmer la présence d'espèces rares ou exotiques. La diversité alpha mesure la richesse et l'abondance des espèces au sein de chaque échantillon tandis que la diversité beta compare la composition des communautés entre échantillons, révélant similitudes et différences entre sites.

Cette étape génère des visualisations, telles que des graphiques de répartition taxonomique ou des arbres phylogénétiques basés sur les ASVs ou OTUs, permettant de transformer les données brutes de séquençage en informations biologiquement significatives et exploitables.

4.2 Exemple de pipelines informatiques

Afin d'illustrer concrètement l'impact du choix du type de lecture sur l'analyse bioinformatique, nous comparons deux pipelines complets utilisés en analyse d'ADNe :

- **FROGS** Find, Rapidly, OTUs with Galaxy Solution : pipeline complet de métabarcoding basé sur l'analyse de lectures courtes et longues, développé par l'INRAE dans le cadre d'études de microbiotes. (voir Figure 5 en Annexe) [12]
- **SAMBA** : pipeline développé par l'IFREMER pour l'analyse d'ADNe à partir de matrices aquatiques, intégrant le traitement de lectures courtes et longues. (voir Figure 6 en Annexe)

Nous allons voir comment fonctionnent ces deux pipelines et comment ils se sont adaptés à l'analyse de lectures longues.

4.2.1 Description globale de FROGS et SAMBA

Les anciennes versions de FROGS étaient surtout optimisées pour les lectures courtes. FROGS 5 intègre désormais des améliorations permettant de traiter efficacement les lectures longues.

Dans le pipeline FROGS, on retrouve en premier lieu l'étape de démultiplexage (étape violette) : on attribue les lectures aux échantillons en fonction des codes-barres internes. Puis il y a l'étape de prétraitement (en rouge). Tout d'abord, si les séquences appartenant à une même lecture (R1 et R2) ne sont pas encore fusionnées, le pipeline les assemble (merging), avant de procéder à une étape de filtrage de qualité, où on retrouve par exemple la déréplication, qui consiste à identifier les séquences identiques afin de réduire leur redondance.
Vient ensuite une étape de clustering, en utilisant **SWARM** (étape bleue). Après celle-ci on supprime les chimères, séquences artefact créées artificiellement durant la PCR, grâce à **VSEARCH** (étape jaune).

L'étape qui suit, en vert, correspond au filtrage des clusters de séquences identiques. Enfin, la classification taxonomique, y compris pour les longs fragments, se fait via l'outil **BLAST**. Une table d'abondance (nombre de séquences par taxon) est crée permettant d'obtenir la biodiversité global retrouvé pour l'échantillon étudié. Une liste de séquences ayant été assignée à plus d'une espèces est aussi générée et correspond ainsi à des séquences ambiguës.

Les avantages principaux de FROGS sont son accessibilité (conçu pour pouvoir être utilisé dans un environnement "Galaxy", accessibles à des biologistes sans compétences informatiques avancées), son traitement complet d'amplicons, sa robustesse et sa sensibilité [10]

Nous allons maintenant présenter le pipeline SAMBA et analyser comment ce prochain pipeline traite les lectures longues.

On distingue dans ce pipeline trois grandes parties : le contrôle d'intégrité des données, le traitement des lectures (longues et courtes) et enfin l'analyse biostatistique finale. SAMBA présente deux approches distinctes entre longues et courtes lectures. Le contrôle d'intégrité permet de vérifier si les fichiers importés sont complets et si les informations en métadonnées correspondent aux données de séquençage.

La partie traitement des lectures courtes reprend des étapes semblables à celles précédemment décrite mais en utilisant des outils différents (QIIME2).

Quant à la partie traitement des lectures longues, le choix des outils est fait spécifiquement pour les lectures longues. En effet comme pour l'étape de mapping, il est utilisé minimap2, dont on a discuté de l'efficacité pour les lectures longues dans la précédente partie.
Il s'en suit alors l'étape d'assignation taxonomique réalisée avec Minimap2 et QIIME2.
Enfin, que ce soient les données de longues ou de courtes lectures, elles convergent ensuite vers un module d'analyse statistique. SAMBA effectue des analyses de la diversité alpha et bêta en utilisant des scripts R.

Dans une comparaison de pipelines d'assignation taxonomique, Rousseau et al. [6] montrent que SAMBA fournit une classification plus précise au niveau du genre bactérien que certains autres outils, ce qui en fait une option fiable pour l'analyse de communautés microbiennes.

4.2.2 Tableau comparatif de FROGS et SAMBA

Étape du pipeline	**FROGS**	**SAMBA**
Démultiplexage Contrôle d'intégrité	Attribution des lectures aux échantillons via codes-barres internes	Vérification de l'intégrité des fichiers et des métadonnées
Prétraitement	Fusion R1/R2 (merging), filtrage qualité, déréplication	Nettoyage lectures courtes avec QIIME2 ; traitement spécifique des lectures longues
Clustering regroupement	Clustering avec SWARM	ASVs via DADA2 ou OTUs, selon type de lecture
Suppression chimères	Avec VSEARCH	Détection et filtrage avec QIIME2 ou DADA2 selon type de lecture
Filtrage des clusters	Filtrage des clusters de séquences identiques	MicroDecon, filtres qualité et décontamination pour lectures courtes et longues
Annotation taxonomique	avec l'outil BLAST	Minimap2 pour long reads, QIIME2 pour short reads
Analyse finale	Table d'abondance	Analyse statistique alpha et beta

TABLE 2 – Comparaison synthétique des étapes principales des pipelines FROGS et SAMBA.

Pour conclure, FROGS a initialement été optimisé pour les lectures courtes, mais les versions récentes permettent désormais de traiter les lectures longues. Il intègre l'outil SWARM pour l'étape de clustering et BLAST pour annoter les deux types de lectures. SAMBA en revanche adopte une stratégie spécifique aux lectures longues en utilisant par exemple Minimap2 pour le mapping de celles-ci. Le choix entre ces deux pipelines dépend du contexte d'étude.

5 Conclusion

Ce projet bibliographique met en évidence l'impact déterminant du type de séquençage sur l'analyse de l'ADN environnemental. Les différents articles ont montré que :

Les lectures courtes offrent une grande fiabilité associé à un coût modéré, mais leur courte longueur limite la résolution taxonomique, et rend difficile l'identification d'espèces très proches.
A l'inverse les lectures longues permettent de couvrir de longues régions génomiques et améliorent alors la résolution taxonomique (identification jusqu'à l'espèce voire la sous-espèce). Toutefois leurs taux d'erreurs historique, leurs coûts et le manque de base de données adaptées restent des limites à prendre en considération.

Les pipelines FROGS et SAMBA illustrent l'influence du type de séquençage sur les outils bioinformatiques choisis. En effet, nous avons pu voir que des stratégies différentes ont été privilégiées de part et d'autre pour l'intégration des séquences en lecture longues. FROGS s'appuie sur un clustering SWARM et une annotation BLAST. A l'inverse SAMBA a recours à des outils conçus pour la spécificité des longues lectures tel que Minimap2 pour le mapping.

Ainsi, l'adéquation entre le type de lecture et les outils bioinformatiques utilisés apparaît comme un axe central pour garantir une identification taxonomique fiable et précise en ADNe.

Les lectures longues sont prometteuses dans le cadre d'analyse d'ADNe en permettant une identification à l'espèce plus performante, cependant nous avons vu que les bases de données de référence ne sont pas encore adaptées à ce type de lecture. Ainsi, le potentiel des lectures longues n'est pas encore entièrement exploité.

6 Bibliographie

Références

[1] Deng J, Zhang X, Yao X, Rao J, Dai F, Wang H, et al. eDNA metabarcoding reveals differences in fish diversity and community structure in Danjiang River. Scientific Reports. 2024 Nov ;14(1) :29460.

[2] Faure N, Manel S, Macé B, Amal V, Guellati N, Holon F, et al. An environmental DNA assay for the detection of Critically Endangered angel sharks (Squatina spp.). Aquatic Conservation-marine And Freshwater Ecosystems. 2023 Oct ;33(10) :1088-97. Available from : https ://archimer.ifremer.fr/doc/00839/95057/.

[3] Espinosa Prieto A, Hardion L, Debortoli N, Bournonville T, Mathot T, Marescaux J, et al. A comparative analysis of eDNA metabarcoding and field surveys : Exploring freshwater plant communities in rivers. Science of The Total Environment. 2024 Dec ;954 :176200. Available from : https ://www.sciencedirect.com/science/article/pii/S0048969724063563.

[4] Tedersoo L, Albertsen M, Anslan S, Callahan B. Perspectives and Benefits of High-Throughput Long-Read Sequencing in Microbial Ecology. Applied and Environmental Microbiology. 2021 Aug ;87(17) :e00626-1. Available from : https ://journals.asm.org/doi/10.1128/aem.00626-21.

[5] Doorenspleet K, Jansen L, Oosterbroek S, Kamermans P, Bos O, Wurz E, et al. The Long and the Short of It : Nanopore-Based eDNA Metabarcoding of Marine Vertebrates Works ; Sensitivity and Species-Level Assignment Depend on Amplicon Lengths. Molecular Ecology Resources. 2025 ;25(4) :e14079. Available from : https ://onlinelibrary.wiley.com/doi/abs/10.1111/1755-0998.14079.

[6] Rousseau C, Henry N, Rousvoal S, Tanguy G, Legeay E, Leblanc C, et al. A Practical Comparison of Short- and Long-Read Metabarcoding Sequencing : Challenges and Solutions for Plastid Read Removal and Microbial Community Exploration of Seaweed Samples. Molecular Ecology Resources. 2025 Oct ;25(7) :e14129.

[7] Piecing together the genome : the long and short of it all – HudsonAlpha Institute for Biotechnology ;. Available from : https ://www.hudsonalpha.org/piecing-together-the-genome-the-long-and-short-of-it-all/.

[8] Ritter CD, Dunthorn M, Anslan S, de Lima VX, Tedersoo L, Nilsson RH, et al. Advancing biodiversity assessments with environmental DNA : Long-read technologies help reveal

the drivers of Amazonian fungal diversity. Ecology and Evolution. 2020 ;10(14) :7509-24. Available from : https ://onlinelibrary.wiley.com/doi/abs/10.1002/ece3.6477.

[9] Li H. Minimap2 : pairwise alignment for nucleotide sequences. Bioinformatics (Oxford, England). 2018 Sep ;34(18) :3094-100.

[10] Escudié F, Auer L, Bernard M, Mariadassou M, Cauquil L, Vidal K, et al. FROGS : Find, Rapidly, OTUs with Galaxy Solution. Bioinformatics. 2018 ;34(8) :1287. Available from : https ://hal.inrae.fr/hal-02626808.

[11] Govender KN, Eyre DW. Benchmarking taxonomic classifiers with Illumina and Nanopore sequence data for clinical metagenomic diagnostic applications. Microbial Genomics. 2022 Oct ;8(10) :mgen000886.

[12] Bernard M, Rué O, Mariadassou M, Pascal G. FROGS : a powerful tool to analyse the diversity of fungi with special management of internal transcribed spacers. Briefings in Bioinformatics. 2021 Nov ;22(6) :bbab318. Available from : https ://academic.oup.com/bib/article/doi/10.1093/bib/bbab318/6354026.

7 Annexes

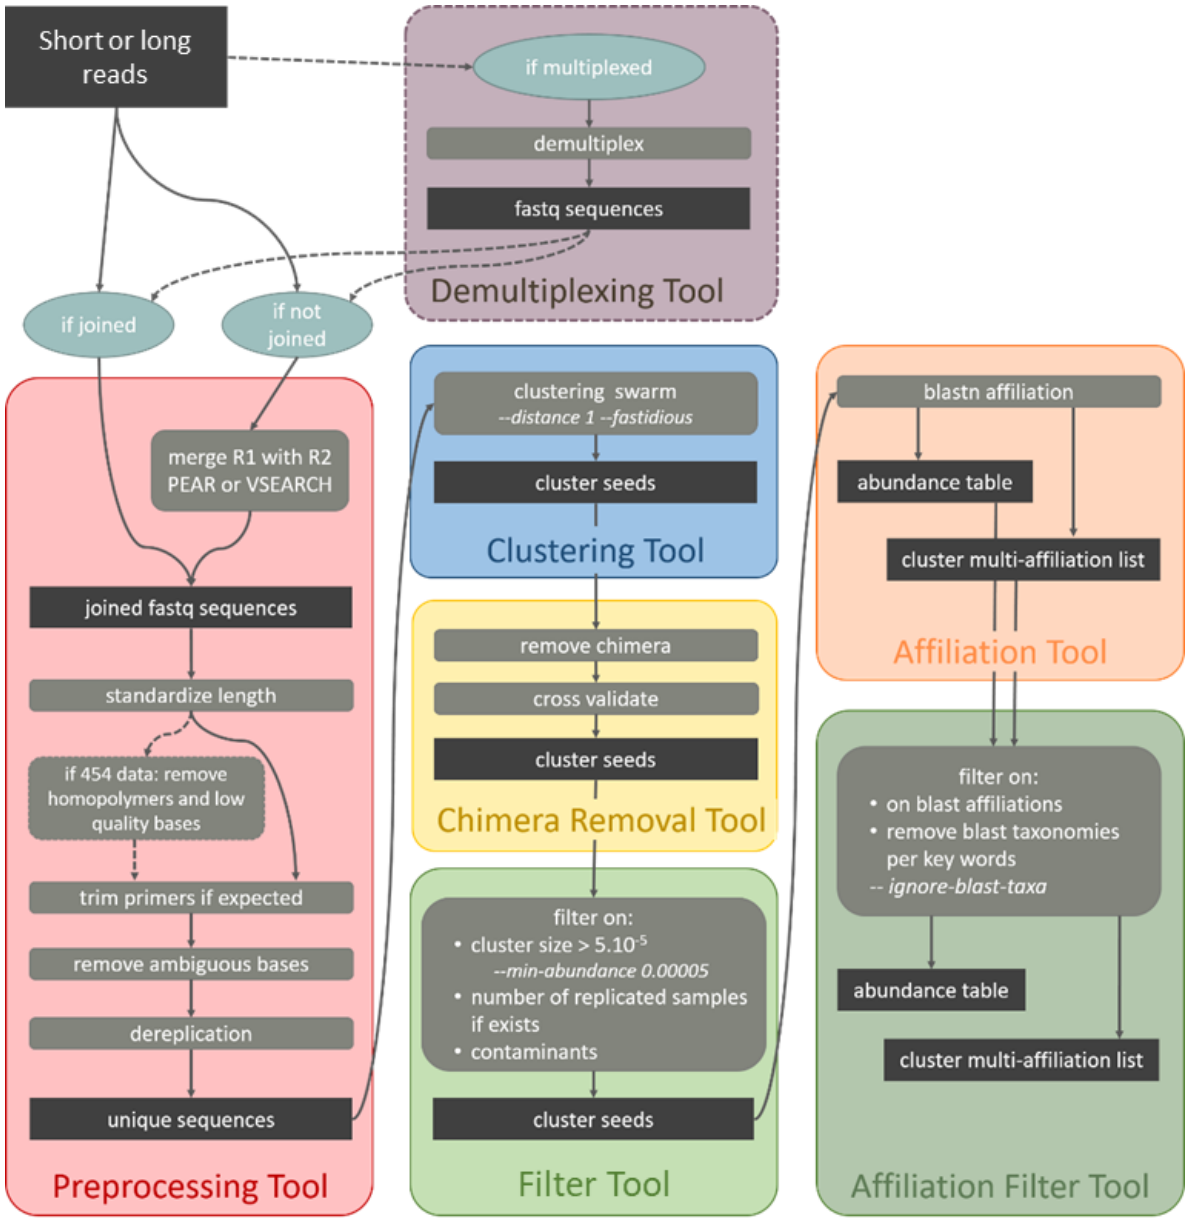

FIGURE 5 – Pipeline FROGS [12]

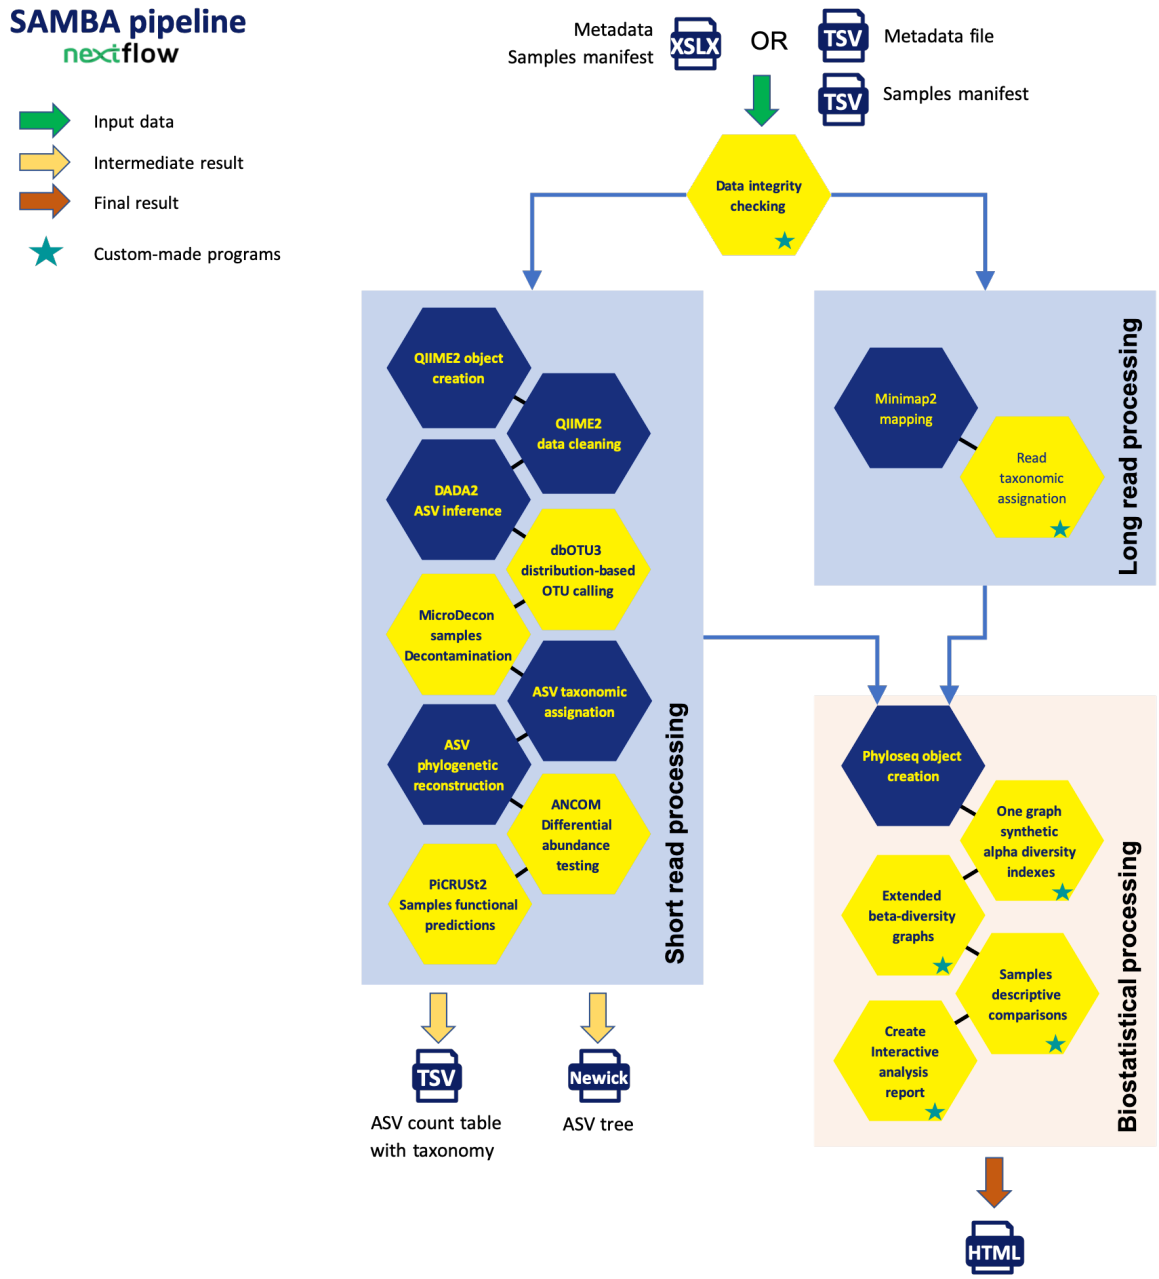

FIGURE 6 – Pipeline SAMBA (tiré du GitHub de l'IFREMER - https ://github.com/ifremer-bioinformatics/samba)